

2. LİTERATÜR

Yaptıkları çalışmada karbon vadeli işlem fiyatlarını tahmin etmek amacıyla ARIMA-CNN-LSTM modeli öneren Zhu ve diğerleri (2019), model yapısında, ARIMA doğrusal özellikleri yakalamak için kullanılmaktadır. CNN ağı verinin hiyerarşik yapısını, LSTM ağı ise verideki uzun dönem bağımlılıkları yakalamak için kullanılmaktadır. Haftalık karbon vadeli işlem fiyatları üzerinde yapılan kapsamlı performans değerlendirmeleri sonucunda, bu modelin Kök Ortalama Kare Hata (RMSE) ve Ortalama Mutlak Yüzde Hata (MAPE) gibi ölçütler açısından temel modellere kıyasla daha yüksek tahmin doğruluğu sağladığı görülmüştür.

Finansal zaman serilerinin tahminlenmesinde model mimarisinin karmaşıklığı, verideki gizli örüntülerin yakalanma düzeyini doğrudan belirlemektedir. Siami-Namini, Tavakoli ve Namin (2019) tarafından gerçekleştirilen karşılaştırmalı analizde; geleneksel ARIMA modelleri ile derin öğrenme tabanlı tek yönlü LSTM ve çift yönlü LSTM (BiLSTM) mimarilerinin performansları incelenmiştir. BiLTSM, ARIMA ve tek yönlü LTSM modeline kıyasla hata oranlarını önemli düzeyde azaltmıştır.

Torgo ve Mozetic (2020) yaptıkları çalışmada performans değerlendirme yöntemleri olan; çapraz doğrulama türleri, örnek dışı yöntemler ve prequential yaklaşımlarını kullanarak iki vaka çalışması incelemiştir. Bu çalışmaların sonucunda durağan serilerde bloklu çapraz doğrulamanın uygun olduğu, durağan olmayan serilerde ise özellikle tekrarlı holdout gibi örnek dışı yöntemlerin daha doğru sonuçlar verdiğini kanıtlamışlardır.

CNN katmanı fiyat serilerindeki yerel özellikleri ve önemli kısa dönemli kalıpları süzmek (feature extraction) amacıyla Lu ve arkadaşları (2020) tarafından önerilen hibrit modelde, LSTM katmanı bu süzülen veriler üzerinden zamansal bağımlılıkları öğrenmek üzere kurgulanmıştır. Bir sonraki günün kapanış fiyatını tahmin etmeyi hedefleyen bu çalışma, hibrit yapının geleneksel tekil modellere kıyasla daha yüksek bir öngörü kapasitesi sunduğunu ortaya koymuştur. Bu bulgular, projemizde benimsenen CNN-LSTM yapısının finansal zaman serilerindeki gürültülü veriyi anlamlandırmada etkili bir seçenek olduğunu doğrulamaktadır.

Finansal varlıkların doğasındaki volatilité seviyesi, model seçiminde belirleyici bir parametredir. Tanışman, Karcioğlu, Uğur ve Bulut (2021), yüksek oynaklığa sahip Bitcoin fiyatlarının tahmini üzerine yaptıkları çalışmada, klasik ARIMA modelleri ile derin öğrenme tabanlı LSTM ağlarını karşılaştırmışlardır. Araştırma bulguları, LSTM modelinin hem yakın hem de uzak gelecek tahminlerinde düşük hata oranları sergileyerek ARIMA modeline göre daha üstün bir performans sunduğunu ortaya koymuştur. Buna karşın ARIMA modelinin, özellikle çok kısa vadeli tahminlerde etkili olabildiği saptanmıştır.

Zaman serisi tahminleme alıřmalarında, verinin ierdiėi karmařıklık ve mevsimsel dler model bařarısını doėrudan etkileyen unsurlardır. Dwivedi, Attry, Parekh ve Singla (2021) tarafından gerekleřtirilen arařtırmada; geleneksel istatistiksel yaklařımlardan mevsimsel etkileri de kapsayan S-ARIMA ile modern derin renme teknikleri olan CNN ve LSTM modelleri karřılařtırmalı olarak ele alınmıřtır. Test sonucunda, model bařarısının veri byklėne ve yapısına gre deėiřkenlik gsterdiėi saptanmıřtır. Derin renme tabanlı yaklařımların karmařık serilerde tahminlerde daha dřk hata payıyla daha etkili sonular rettiėini kanıtlamıřtır. Bu bulgular, projemizde kullanılan CNN-LSTM mimarisinin finansal verilerdeki gizli rntleri yakalama potansiyelini desteklemektedir.

Yurduseven ve Mngen (2022) tarafından yapılan kapsamlı literatr derlemesinde, finansal piyasalardaki yksek oynaklık ve doėrusal olmayan yapıyı czmede yapay sinir aėlarının geleneksel yntemlere kıyasla daha esnek ve uyumlu bir yapı sunduėu vurgulanmıřtır. Yazarlar, tek bir modelin her zaman yeterli olmadıėını; verinin duraėanlıėı ve karmařıklık dzeyine gre klasik ARIMA modelleri ile modern makine renmesi yaklařımları arasında stratejik bir seim yapılması gerektiėini belirtmiřlerdir. Bu alıřma, projemizde tekil modeller yerine hibrit ve esnek mimarilerin tercih edilmesinin akademik gerekelerini genel bir perspektifle desteklemektedir.

Hisse senedi tahmininin yksek belirsizlik ve ok sayıda etkileyici faktr nedeniyle klasik zaman serisi yntemleriyle sınırlı kaldıėını vurgulayan Akřehir ve Kılı (2022), bu sorunu ařmak iin alıřmada, veri dengesizliėini azaltmaya ynelik kural tabanlı bir etiketleme yntemi ve daha etkili bir zellik seimi yaklařımı nerilmiřtir. Dow30 endeksi zerinde geliřtirilen CNN tabanlı modelde, teknik gstergeler ile altın ve petrol fiyatları kullanılarak oluřturulan veri setleri zerinden tahminler yapılmıřtır. Sonular, nerilen yaklařımın hem doėruluk oranını artırdıėını hem de veri dengesizliėi problemini nemli lde azalttıėını gstermektedir.

Wang ve Li (2022) tarafından gerekleřtirilen alıřmada, hisse senedi fiyatlarını tahmin etmek amacıyla ARIMA ve LSTM modellerinin entegre edildiėi hibrit bir yapı nerilmiřtir. Bu modelde ARIMA, zaman serisindeki doėrusal (lineer) bileřenleri modellemek zere konumlandırılırken; LSTM aėı, serideki doėrusal olmayan iliřkileri ve uzun dnemli baėımlılıkları renmek iin kullanılmıřtır. Deneysel sonular, bu hibrit yaklařımın tek bařına kullanılan ARIMA ve LSTM modellerine kıyasla daha dřk hata oranları saėladıėını ortaya koymuřtur. Bu bulgular, alıřmamızda benimsenen hibrit metodolojinin verideki karmařık yapıları yakalamadaki teorik stnlėn desteklemektedir.

Finansal piyasalardaki kısa vadeli fiyat trendlerinin tahmininde hibrit veri girişlerinin etkisini inceleyen ve bu çalışmanın temel metodolojik dayanağını oluşturan araştırmada (Van der Burgt, J.J., 2023); ARIMA, LSTM ve 1D-CNN modellerinin performansları kapsamlı bir şekilde karşılaştırılmıştır. Bu çalışma, literatürdeki diğer örneklerden farklı olarak, tarihsel fiyat verilerinin yanı sıra RSI (Göreceli Güç Endeksi) ve Hareketli Ortalama gibi teknik göstergelerin modele dahil edilmesinin tahmin başarısını nasıl optimize ettiğini ortaya koymuştur. NASDAQ100 endeksi verileri üzerinden yapılan analizler, özellikle LSTM mimarisinin teknik indikatörlerle birleştirildiğinde karmaşık piyasa dinamiklerini anlamlandırmada üstünlük sağladığını ve tahmin penceresi genişletildikçe modelin kalıpları daha yüksek doğrulukla yakaladığını kanıtlamıştır.

Albeladi, Zafar ve Muuen (2023) gayrimenkul verileri üzerinde Python tabanlı LSTM ve ARIMA modelleri karşılaştırılmıştır. Çalışma bulguları, temel performans metrikleri açısından ARIMA modelinin LSTM'e kıyasla daha tutarlı ve başarılı sonuçlar verdiğini ortaya koymuştur. Bu durum, finansal zaman serilerinin yapısına bağlı olarak doğrusal kombinasyonların (ARIMA), karmaşık örüntüleri hatırlama yeteneğine sahip sinir ağlarından (LSTM) daha verimli olabileceğini göstermesi bakımından projemiz için önemli bir karşıt referans noktası teşkil etmektedir.

Sandhya V, Shailaja S, Sai Ramya K, (2023) gelişmekte olan piyasalardaki volatilitiyi tahmin etmek amacıyla tarihsel fiyatları, makroekonomik göstergeleri ve duygu (sentiment) verilerini birleştiren hibrit bir yaklaşım sunmuştur. Finansal piyasaların doğrusal olmayan yapısı ve yüksek frekanslı dalgalanmaları karşısında geleneksel ekonometrik modeller yetersiz kalabildiği için çalışma özellikle Uzun Kısa Süreli Bellek (LSTM) ağlarının, ani volatilité sıçramalarını yakalamada GARCH gibi geleneksel modellerden çok daha üstün bir performans sergilediğini ortaya koymuştur.

Yılmaz (2024), 2014-2022 dönemine ait verilerle eğittiği çok katmanlı ileri beslemeli Yapay Sinir Ağları (YSA) modellerini kullanarak BIST 100 endeksinin 2023-2024 dönemi öngörülerini analiz etmiştir. Çalışma sonucunda, test edilen modellerin büyük çoğunluğunun %60'ın üzerinde bir açıklayıcılık (R^2) oranına ulaştığı ve en yüksek başarının %63,2 ile Model 4'te olduğu belirlenmiştir. Bu çalışma, YSA yönteminin BIST verileri üzerindeki tahmin kapasitesini güncel bir perspektifle ortaya koyarak, projemizde uygulanan derin öğrenme modellerinin yerel piyasa dinamiklerini yakalama potansiyelini desteklemektedir.

Küresel ekonomik belirsizliklerin pay piyasaları üzerindeki etkisini derin öğrenme mimarileriyle inceleyen güncel çalışmalarda, dışsal volatilité değişkenlerinin model başarısı üzerindeki kritik rolü vurgulanmaktadır. Bu bağlamda Sönmez ve Coşkun Arslan (2024), 2012-2024 dönemini kapsayan araştırmalarında BIST 100 ve DAX endekslerinin tahmini için LSTM (Uzun Kısa Süreli Bellek) ağlarının performansını değerlendirmişlerdir. Analiz sonuçları, LSTM mimarisinin yüksek oynaklık içeren veri setlerinde hem yerel (BIST 100) hem de küresel (DAX) ölçekte üstün bir öngörü kapasitesine sahip olduğunu ortaya koymuştur. Özellikle BIST 100 endeksi için elde edilen 0.9948'lik açıklayıcılık oranı (R^2), derin öğrenme modellerinin dışsal risk faktörlerini anlamlandırmadaki başarısını kanıtlar niteliktedir.

Sarıgül, Aldemir, Uzunoğlu (2024) Makine Öğrenmesi algoritmalarını kullanarak Sınai Endeksi, Hizmetler Endeksi ve Mali Endeks firmalarının 2019-2024 yılı verileri analiz etmiş ve bu yöntemlerin hisse senedi endekslerini tahmin etmede etkili olduğunu, finansal tahminlerde giderek daha çok kullanılacağını öne sürmüştür.

Kırelli (2024) tarafından teknoloji sektörü verileri (Oracle) üzerinden gerçekleştirilen karşılaştırmalı analizde, LSTM ve ARIMA modellerinin performansları MSE, MAE, RMSE ve MAPE gibi kapsamlı metrikler kullanılarak değerlendirilmiştir. Araştırma sonuçları, LSTM modelinin esnek yapısı sayesinde genel olarak daha düşük hata değerleri ürettiğini ve karmaşık veri setlerinde önemli artılar sunduğunu ortaya koymuştur. ARIMA modelinin belirli durumlarda daha stabil ve oransal olarak tutarlı tahminler üretebildiğine dikkat çekmiştir. Bu bulgular, çalışmamızda kullanılan derin öğrenme modellerinin performansını ölçerken çok boyutlu bir hata analizi yapmanın önemini desteklemektedir.

Munthe ve diğerleri (2024) makine öğrenmesi (XGBoost, Random Forest) ve derin öğrenme (LSTM) algoritmalarını yığma tekniği ile birleştiren yenilikçi bir model önermiştir. Bu çalışmada, alt modellerden gelen tahminlerin bir 'meta-model' (Lojistik Regresyon veya LSTM) aracılığıyla harmanlanmasının, tekil modellerin performansını aşarak %86 doğruluk oranına ulaştığı saptanmıştır. Bu bulgular, projede kullanılan CNN ve LSTM yapılarının tek başlarına değil, birleşik bir hiyerarşi içinde kullanılmasının potansiyel avantajlarını ortaya koymaktadır.

Zhang (2024) Zaman serisi tahmininde ARIMA, CNN ve LSTM modellerinin entegre edildiği hibrit yaklaşımların, hisse senedi endeksi tahmininde tekil modellere kıyasla daha yüksek doğruluk ve daha güçlü model kararlılığı sağladığı gösterilmiştir. Önerilen bu entegre yapının model kararlılığı açısından da daha güçlü bir performans sergilemesi, finansal zaman serilerinin analizinde hibrit sistemlerinin kullanımı destekleyen önemli bir bulgudur.

Zaman serisi tahminleme doğruluğunu maksimize etmek için geliştirilen güncel yaklaşımlardan biri olan 'Residual-Corrected Hybrid' (Hata Düzeltmeli Hibrit) çerçevesi, Huang ve Zhou (2025) tarafından önerilmiştir. Bu çalışmada yazarlar, tahmin problemini lineer ve lineer olmayan bileşenlere ayırmıştır. Lineer bileşenler ARIMA modeli ile tahmin edilirken, ARIMA'dan elde edilen hata (residual) değerleri üzerinden lineer olmayan ilişkileri yakalamak amacıyla CNN-LSTM mimarisi kullanılmıştır. Araştırma sonuçları, bu residual düzeltme mekanizmasının tekil modellere kıyasla yüksek bir açıklayıcılık oranı sağladığını ve performansın ARIMA'ya göre %10.5, tekil CNN-LSTM'e göre ise %13.1 oranında iyileştiğini kanıtlamıştır. Bu yöntem, projemizde kurulan modelin hem zamansal bağımlılıkları hem de lokal anomalileri bir arada öğrenebilmesi adına temel bir metodolojik dayanak oluşturmaktadır.

2014-2025 dönemini kapsayan günlük BIST100 endeksi verileri ile yaptıkları analizde; LSTM, BILSTM ve CNN-LSTM modellerini karşılaştırmalı olarak inceleyen Varürer, Özaydın ve Çemrek (2025), LSTM, BILSTM ve CNN-LSTM modellerini karşılaştırmalı olarak incelemişlerdir. En düşük hata oranını (RMSE: 170.87) sergileyen CNN-LSTM modelinin, tekil LSTM ve BILSTM yapılarından daha üstün bir tahmin performansı sunduğu saptanmıştır. Bu bulgular, hibrit derin öğrenme modellerinin yerel piyasalardaki karmaşık ve çok değişkenli yapıyı öğrenmedeki kapasitesini doğrulamaktadır.

Alharbi (2025) tarafından gerçekleştirilen çalışmada, TASI endeksinde yer alan hisse senedi fiyatlarını tahmin etmek üzere ARIMA-LSTM tabanlı hibrit bir model önerilmiştir. Tahmin süreci, serideki doğrusal bileşenlerin ARIMA ile modellenmesi ve ardından bu aşamadan elde edilen artıkların (residuals) doğrusal olmayan karmaşık örüntüleri yakalamak üzere LSTM ağına aktarılması prensibiyle kurgulanmıştır. Araştırma bulguları, önerilen hibrit mimarinin hem ARIMA'nın istatistiksel trend belirleme yeteneğinden hem de LSTM'in derin öğrenme kapasitesinden faydalanarak tekil modellerden daha yüksek bir öngörü hassasiyeti sergilediğini ortaya koymuştur.

AIP Conference Proceedings (2025) kapsamında yayınlanan güncel bir çalışmada, hisse senedi piyasası tahmini için ARIMA ve CNN-LSTM mimarilerinin performansları değerlendirilmiştir. Araştırma sonuçları, ARIMA modelinin serideki doğrusal ilişkileri modellemedeki başarısına rağmen; CNN-LSTM modelinin doğrusal olmayan eğilimleri ve karmaşık zamansal bağımlılıkları öğrenme kapasitesi sayesinde çok daha yüksek bir tahmin doğruluğu sergilediğini ortaya koymuştur. Bununla birlikte çalışma, ARIMA'nın daha basit bir yapıya sahip olması nedeniyle belirli durumlarda kısa vadeli tahminlerde etkili olabildiğini, ancak genel başarının derin öğrenme tabanlı hibrit modellerde toplandığını doğrulamaktadır.